Data Analysis Textbook

SQL app　Excel Microsoft 365　Python pandas

データ分析の教科書

第 1 部・第 2 部　Part 1–2 · Unit A1–A6

数字の裏にある事実を、3 つの道具で確かめる。

Find the facts behind the numbers, and check them with three tools.

kumo_mart.sql

```sql
-- How much does a typical order cost?
SELECT ROUND(AVG(amount), 1) AS mean,
       (SELECT amount FROM kumo_orders
        ORDER BY amount LIMIT 1 OFFSET 200) AS median
FROM kumo_orders;
```

結果　1 row

mean	median
5351.4	4390

No.	名前 Name

この本の使い方 How to use this book

1 つの Unit は見開き 2 ページ。アプリで SQL を書き、同じ問いを Excel と Python でも解く。

Each unit is a two-page spread. Write the SQL in the app, then solve the same question in Excel and Python.

左のページ left page

① 依頼とゴール

Request and goal

クモマートの誰かからの依頼と、

この Unit でできるようになること。

A request from someone at Kumo Mart, and what you will be able to do.

② 統計の基礎

Statistics basics

式の意味を、本当のデータで描いた図で見る。

The meaning of the formula, with a figure drawn from the real data.

③ 見てみる

See it

クモマートのデータで SQL を実行した結果。

The SQL run on the Kumo Mart data, and its result.

右のページ right page

④ ポイント・よくある間違い

Points, common mistakes

× の SQL を実行するとどうなるか。

What happens when the × SQL runs.

⑤ Excel・Python

Excel, Python

同じ問いを Excel と Python でも解く。

同じ数字が出れば正解。

Solve the same question in Excel and Python. The same numbers mean you are right.

⑥ やってみよう

Try it

別の業種のデータで練習。答えは巻末。

Practise on data from other businesses. Answers are at the back.

分析の流れ The analysis process

問う Ask → 集める Collect → 整える Clean → 分析する Analyse → 伝える Share

どの Unit も、この流れのどこかを練習している。用語は英語も一緒に覚えると、英語の資格試験もそのまま読める。

Every unit practises part of this process. Learn the English terms too, so you can read English certification exams.

CSV と道具 CSV and tools

SQL

アプリの「データ分析」の章。

問題の下のボタンで Excel・Python のガイドが開く。

The “Data analysis” chapter of the app. The buttons under each problem open the Excel and Python guides.

Py

Python は VS Code か Jupyter。

pandas・matplotlib を使う。

ガイドからノートブックも保存できる。

Python runs in VS Code or Jupyter with pandas and matplotlib. The guide can also save a notebook.

X

Excel は Microsoft 365。

表の「CSV」ボタンで保存したファイルを開く。

Excel is Microsoft 365. Open the file saved with the CSV button of the table.

各 Unit のページの QR コードで、アプリのその Unit が開く。

The QR code on each unit opens that unit in the app.

講座の地図 Course map

全 22 Unit・7 部で、基礎統計を一通り学ぶ。この本は色のついた第 1 部・第 2 部。

22 units in 7 parts cover basic statistics. This book is the coloured Parts 1 and 2.

第 1 部
データと向き合う準備
Part 1 · Getting ready

- A1 **データの全体を見る** — Get to know the data
- A2 **欠損値と重複** — Missing values, duplicates

第 2 部
1 つの数値を要約する
Part 2 · Summarise one number

- A3 **平均と中央値** — Mean, median, mode
- A4 **散らばり** — Spread
- A5 **度数分布** — Histograms
- A6 **標準化と外れ値** — z-scores, outliers

第 3 部
比べる・組み合わせる
Part 3 · Compare and combine

- A7 グループの比較 — Compare groups
- A8 構成比とパレート図 — Shares, Pareto
- A9 クロス集計 — Cross tables
- A10 表を結合する — Joining tables

第 4 部
時間で見る
Part 4 · Over time

- A11 月ごとの動き — Monthly trends
- A12 前年比と移動平均 — Growth, moving averages
- A13 順位 — Ranking
- A14 リピート率 — Retention

第 5 部
関係を調べる
Part 5 · Relationships

- A15 相関 — Correlation
- A16 回帰と予測 — Regression

第 6 部
確からしさを判断する
Part 6 · Inference

- A17 確率分布 — Distributions
- A18 推定 — Estimation
- A19 A/B テスト — A/B tests
- A20 カイ二乗検定 — Chi-square test

第 7 部
伝える・総合
Part 7 · Share, project

- A21 グラフを正しく読む — Reading charts
- A22 総合プロジェクト — Final project

この本でできるようになること What you will be able to do

できるようになったら、☐ にチェックを入れよう。

Tick each box when you can do it.

- ☐ 列の種類（量的・質的）を言える — name the kind of each column — A1
- ☐ 欠損率と重複を数えて報告できる — report missing values and duplicates — A2
- ☐ 平均・中央値・最頻値を使い分けられる — choose between mean, median and mode — A3
- ☐ 標準偏差で散らばりを比べられる — compare spread with the standard deviation — A4
- ☐ 度数分布表を作り、形を読める — make a frequency table and read its shape — A5
- ☐ z 得点で外れ値の候補を見つけられる — find outlier candidates with z-scores — A6

目次 Contents

データと向き合う準備 Part 1・Getting ready

Unit A1 データの全体を見る Get to know the data p.6

Unit A2 欠損値と重複を数える Count missing values and duplicates p.8

1つの数値を要約する（記述統計） Part 2・Summarise one number (descriptive statistics)

Unit A3 平均と中央値 Mean, median and mode p.10

Unit A4 散らばりを測る Measure the spread p.12

Unit A5 度数分布とヒストグラム Frequency tables and histograms p.14

Unit A6 標準化と外れ値 Standard scores and outliers p.16

答え Answers

やってみようの答え Answers to “Try it” p.18

クモマートのデータ The Kumo Mart data

クモマート（Kumo Mart）は、3 つの店とネット通販を持つ架空の会社。例題はすべてこのデータを使う。
アプリと同じデータなので、結果を確かめられる。

Kumo Mart is a made-up company with three stores and an online shop. All examples use its data, which is the same as in the app.

`kumo_orders` 注文（全部で 401 行、最初の 8 行） orders (401 rows, the first 8)

order_id	order_date	store	customer_id	amount	items	coupon
1	2025-01-01	Sakae	C102	2090	4	SPRING5
2	2025-01-02	Online	C042	7110	2	*NULL*
3	2025-01-03	Online	C081	2880	5	WELCOME10
4	2025-01-03	Sakae	C034	4660	1	APP300
5	2025-01-03	Umeda	C031	2090	6	*NULL*
6	2025-01-05	Online	C104	7690	1	*NULL*
7	2025-01-07	Sakae	C088	5390	1	*NULL*
8	2025-01-08	Shibuya	C089	7560	2	*NULL*

order_id	注文番号 order number
order_date	注文日（2025 年） order date (2025)
store	店（Shibuya・Umeda・Sakae・Online） store
customer_id	客の番号（同じ客が何度も買う） customer (repeats)
amount	金額（円） amount (yen)
items	買った点数 number of items
coupon	使ったクーポン（空欄あり） coupon used (may be blank)

顧客名簿 kumo_customers（customer_id・joined_date・city・name・points・age・email）は A2 で使う。

The customer list kumo_customers is used in A2.

練習で使う表 Tables for practice

「やってみよう」とアプリの演習では、別の業種のデータで同じ方法を使う。

In “Try it” and in the app, the same methods are used on data from other businesses.

表 table	内容 about	行数 rows	列 columns
cafe_sales	カフェの売上 cafe sales	151	`sale_id, sale_date, shop, member_id, amount, cups, coupon`
hotel_stays	ホテルの宿泊 hotel stays	131	`stay_id, checkin_date, hotel, guest_id, charge, nights, request`
courier_jobs	宅配の料金 courier jobs	141	`delivery_id, ship_date, region, client_id, fee, days, note`
helpdesk_tickets	IT ヘルプデスクの対応 IT help desk tickets	121	`ticket_id, opened_date, team, user_id, minutes, replies, rating`
gym_visits	ジムの利用 gym visits	161	`visit_id, visit_date, branch, member_id, minutes, machines, trainer`
factory_lots	工場の製品検査 factory quality checks	111	`lot_id, made_date, line, operator_id, weight_g, defects, inspector`

分析 Unit A1

データの全体を見る COUNT・MIN・MAX

Get to know the data

アプリで練習
Practice in the app

SQL Excel Python

店長 Store manager

「最近、売上が落ちた気がする。」答える前に、どんなデータがあるかを確かめよう。

"I feel sales have dropped lately." Before answering, check what data we have.

行数・値の範囲・期間を調べ、列の種類を言える。

You can find the number of rows, the range of values and the period, and name the kind of each column.

統計の基礎 Statistics basics

データの種類 Kinds of data

- 量的データ：計算できる数（金額、個数）
  Quantitative: numbers you can calculate with (amount, items)
- 質的データ：ラベル（店、クーポン）。名義尺度は順番なし、順序尺度は順番あり（S・M・L）
  Qualitative: labels (store, coupon). Nominal has no order, ordinal has an order (S, M, L)
- 日付：順番があり、日数を数えられる
  Dates: they have an order, and you can count days between them

母集団と標本 Population and sample

母集団は知りたいもの全部（すべての客）、
標本は手元にある一部（今年の注文）。統計は、
標本から母集団を知るための道具。

The population is everything you want to know about (all customers); a sample is the part you have (this year's orders). Statistics learns about the population from a sample.

order_id	ID id
order_date	日付 date
store	質的 qualitative
customer_id	質的 qualitative
amount	量的 quantitative
items	量的 quantitative
coupon	質的 qualitative

kumo_orders の列と、その種類。

The columns of kumo_orders and their kinds.

見てみる See it

kumo_orders の行数、amount の最小と最大、最初と最後の日付を求める。

Find the number of rows, the smallest and largest amount, and the first and last date of kumo_orders.

```sql
SELECT COUNT(*) AS n_rows,
       MIN(amount) AS min_amount, MAX(amount) AS max_amount,
       MIN(order_date) AS first_date, MAX(order_date) AS last_date
FROM kumo_orders;
```

結果 1行 1 row

n_rows	min_amount	max_amount	first_date	last_date
401	820	68400	2025-01-01	2025-12-31

2025 年の 1 年分、401 件の注文。金額の幅はとても広い。

One year (2025), 401 orders. The amounts vary a lot.

ポイント Points

1. 分析の流れ：問う → 集める → 整える → 分析する → 伝える。この Unit は「集める」の最初の 1 歩。
   The analysis process: ask → collect → clean → analyse → share. This unit is the first step of "collect".
2. いきなり細かく見ない。まず行数・範囲・期間で全体をつかむ。
   Do not start with the details. First get the whole picture: rows, range, period.
3. 日付は '2025-01-31' の形の文字なので、MIN と MAX で最初と最後が分かる。
   Dates are text like '2025-01-31', so MIN and MAX give the first and last.

よくある間違い Common mistakes

✕
```
SELECT COUNT(coupon)
FROM kumo_orders;
```

実行結果 1行 1 row

COUNT(coupon)
~~401~~
143

→ 結果の値がちがう
→ different values in the result

COUNT(列) は NULL を数えない。行数は COUNT(*) で数える。
COUNT(column) does not count NULL. Count rows with COUNT(*).

◯
```
SELECT COUNT(*)
FROM kumo_orders;
```

X Excel でやってみる Excel (Microsoft 365)

1. アプリの「CSV」ボタンで表を保存し、Excel で開く。Ctrl + T でテーブルにして、名前を kumo_orders にする。
   Save the table with the app's CSV button and open it in Excel. Press Ctrl + T to make a table and name it kumo_orders.
2. 行数、amount の最小と最大：
   Rows, smallest and largest amount:
```
=ROWS(kumo_orders)
=MIN(kumo_orders[amount])
=MAX(kumo_orders[amount])
```
3. 最初と最後の日付。45658 のような数が出たら、表示形式を「日付」にする。
   First and last date. If you see a number like 45658, set the number format to Date.
```
=MIN(kumo_orders[order_date])
=MAX(kumo_orders[order_date])
```

SQL と同じ数字になれば正解。
If you get the same numbers as the SQL, you are right.

Py Python でやってみる

Python (pandas・VS Code / Jupyter)

1. CSV をノートブックと同じフォルダに置き、pandas で読み込む。
   Put the CSV in the same folder as your notebook and read it with pandas.
```
import pandas as pd
df = pd.read_csv("kumo_orders.csv")
```
2. 行数・範囲・期間。df.info() で列ごとの型も分かる。
   Rows, range, period. df.info() also shows the type of each column.
```
print(len(df))
print(df["amount"].min(), df["amount"].max())
print(df["order_date"].min(),
df["order_date"].max())
df.info()
```

SQL と同じ数字になれば正解。
If you get the same numbers as the SQL, you are right.

やってみよう Try it

1. cafe_sales の行数と、amount の最小・最大を求めよう。
   Find the number of rows and the smallest and largest amount of cafe_sales.
   結果：1行 1 row

2. hotel_stays の checkin_date の最初と最後を求めよう。
   Find the first and last checkin_date of hotel_stays.
   結果：1行 1 row

3. gym_visits の列を、量的・質的・日付・ID に分けよう。
   Sort the columns of gym_visits into quantitative, qualitative, date and ID.
   列は 7 つ 7 columns

分析 Unit A2

欠損値と重複を数える

COUNT(列)・DISTINCT

Count missing values and duplicates

アプリで練習
Practice in the app

SQL Excel Python

マーケティング部 Marketing team

「会員にメールを送りたい。何人に送れる？」名簿には空欄と二重登録がある。

"We want to e-mail our members. How many can we reach?" The list has gaps and double sign-ups.

空欄（NULL）と重複の数を数え、割合で報告できる。

You can count missing values (NULL) and duplicates and report them as a percentage.

統計の基礎 Statistics basics

実際のデータには必ず空欄がある。欠損率は、
空欄の数を全体の行数で割る。

Real data always has gaps. The missing rate is the number of blanks divided by all rows.

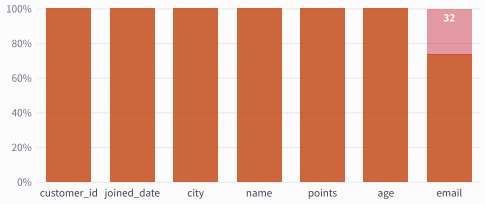
欠損率 (%) = (COUNT(*) − COUNT(列)) ÷ COUNT(*) × 100

どうするかは、なぜ空欄かで決める。
行を除く・値を埋める・「不明」として残す。除いた数は必ず報告する。

What to do depends on why it is missing: drop the row, fill it in, or keep "unknown". Always report how many you dropped.

同じ人が 2 回登録されることもある。
COUNT(DISTINCT 列) は同じ値を 1 回だけ数える。

The same person may sign up twice. COUNT(DISTINCT column) counts each value once.



kumo_customers の列ごとの、
値が入っている割合（青）と空欄（赤、数字は件数）。

Per column of kumo_customers: filled (blue) and missing (red, with the count).

見てみる See it

kumo_customers の email について、入力あり・空欄・欠損率を求める。

For email in kumo_customers, find filled, missing and the missing rate.

```sql
SELECT COUNT(*) AS n_rows,
       COUNT(email) AS filled,
       COUNT(*) - COUNT(email) AS missing,
       ROUND(100.0 * (COUNT(*) - COUNT(email)) / COUNT(*), 1) AS missing_pct
FROM kumo_customers;
```

結果 1行 1 row

n_rows	filled	missing	missing_pct
121	89	32	26.4

メールを送れるのは 89 人…ではない。二重登録があるので、次に重複を数える。

We cannot simply e-mail 89 people: there are double sign-ups, so count duplicates next.

重複を数える Count duplicates

```sql
SELECT COUNT(name) AS n_rows,
       COUNT(DISTINCT name) AS unique_name
FROM kumo_customers;
```

n_rows	unique_name
121	98

121 行あるのに、名前は 98 種類。差の 23 行は、同じ人かどうか確かめる。

121 rows but only 98 different names. Check whether the other 23 rows are the same people.

ポイント Points

1. COUNT(*) は全部の行、COUNT(列) は NULL でない行を数える。差が空欄の数。
   COUNT(*) counts all rows, COUNT(column) the non-NULL ones. The difference is the number of blanks.
2. 割合は 100.0 を掛けてから割る。小数の計算になる。
   For a percentage, multiply by 100.0 first, so the division keeps decimals.

よくある間違い Common mistakes

✕
```
SELECT ROUND(100 * (COUNT(*) - COUNT(email)) / COUNT(*), 1)
FROM kumo_customers;
```

実行結果 1行 1 row

ROUND(100 * (COUNT(*) - COUNT(email)) / COUNT(*), 1)
~~26.4~~
26

→ 結果の値がちがう
→ different values in the result

整数どうしの割り算は、小数が切り捨てられる。
Dividing an integer by an integer drops the decimals.

○
```
SELECT ROUND(100.0 * (COUNT(*) - COUNT(email)) / COUNT(*), 1)
FROM kumo_customers;
```

Excel でやってみる Excel (Microsoft 365)

1. アプリの「CSV」ボタンで表を保存し、Excel で開く。
   Ctrl + T でテーブルにして、
   名前を kumo_customers にする。
   Save the table with the app's CSV button and open it in Excel. Press Ctrl + T to make a table and name it kumo_customers.
2. 行数・入力あり・空欄・欠損率：
   Rows, filled, blank, missing rate:
```
=ROWS(kumo_customers)
=COUNTA(kumo_customers[email])
=COUNTBLANK(kumo_customers[email])
=ROUND(100*COUNTBLANK(kumo_customers[email])/ROWS(
kumo_customers),1)
```
3. 重複を除いた名前の数（UNIQUE は Microsoft 365）：
   Different names (UNIQUE needs Microsoft 365):
```
=COUNTA(UNIQUE(kumo_customers[name]))
```

SQL と同じ数字になれば正解。
If you get the same numbers as the SQL, you are right.

Python でやってみる

Python (pandas · VS Code / Jupyter)

1. CSV をノートブックと同じフォルダに置き、
   pandas で読み込む。
   Put the CSV in the same folder as your notebook and read it with pandas.
```
import pandas as pd
df = pd.read_csv("kumo_customers.csv")
```
2. 空欄の数（全部の列）と、名前の種類：
   Blanks in every column, and the number of different names:
```
print(df.isna().sum())
missing = df["email"].isna().sum()
print(round(100 * missing / len(df), 1))
print(df["name"].nunique())
```

SQL と同じ数字になれば正解。
If you get the same numbers as the SQL, you are right.

やってみよう Try it

1. helpdesk_tickets の rating の空欄の数と欠損率（%、小数第 1 位）を求めよう。
   Find the number of blanks and the missing rate (%, 1 decimal place) of rating in helpdesk_tickets.
   結果：1 行 / 1 row

2. courier_jobs の client_id は何種類ある？
   How many different client_id are there in courier_jobs?
   結果：1 行 / 1 row

3. cafe_sales で、一度でも来た member_id の数と、全部の行数を並べて出そう。
   Show the number of different member_id next to the number of rows in cafe_sales.
   結果：1 行 / 1 row

分析 Unit A3

平均と中央値 AVG・中央値

Mean, median and mode

アプリで練習
Practice in the app

SQL Excel Python

店長 Store manager

「客単価はいくら？高額の注文に引っ張られていない？」

“How much does a customer spend per order? Are a few big orders pulling the number up?”

平均・中央値・最頻値を求め、どれが「ふつうの値」に近いかを説明できる。

You can find the mean, median and mode and explain which is closer to a typical value.

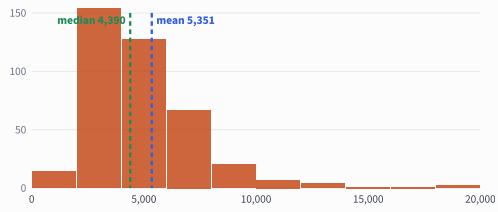
統計の基礎 Statistics basics

- 平均（mean）：合計 ÷ 個数
  Mean: the sum ÷ the number of values
- 中央値（median）：小さい順に並べた真ん中。
  n 個なら (n + 1) ÷ 2 番目
  Median: the middle value when sorted; with n values, the (n + 1) ÷ 2-th
- 最頻値（mode）：いちばん多く出てくる値
  Mode: the value that appears most often

平均 $\bar{x} = (x_1 + x_2 + \dots + x_n) \div n$

とても大きな値が少しあると、平均は引っ張られるが、
中央値は動かない。お金のデータは右に長いすそがあり、
平均が中央値より大きくなりやすい。

A few very large values pull the mean up, but not the median. Money data has a long right tail, so the mean is usually larger than the median.



amount のヒストグラム。青が平均、緑が中央値。
20,000 円以上の 4 件（最大 68,400 円）は図の外。

Histogram of amount: mean (blue), median (green). 4 orders of 20,000 yen or more (up to 68,400) are beyond the right edge.

見てみる See it

amount の平均と中央値を求める。401 行なので、中央値は小さい順で 201 番目。

Find the mean and median of amount. With 401 rows, the median is the 201th value.

```sql
SELECT ROUND(AVG(amount), 1) AS mean_amount,
       (SELECT amount FROM kumo_orders
        ORDER BY amount LIMIT 1 OFFSET 200) AS median_amount
FROM kumo_orders;
```

結果 1 行 1 row

mean_amount	median_amount
5351.4	4390

平均 5,351.4 円は、中央値 4,390 円よりかなり大きい。客単価の「ふつう」は中央値で伝える。

The mean (5,351.4 yen) is much larger than the median (4,390 yen). Report the typical order with the median.

ポイント Points

1. 括弧の中の SELECT（サブクエリ）が、中央値を 1 つの値として返す。
   The SELECT inside the brackets (a subquery) returns the median as one value.
2. OFFSET k は「k 行とばす」。真ん中の前にある (n − 1) ÷ 2 行をとばす。
   OFFSET k skips k rows: skip the (n − 1) ÷ 2 rows before the middle one.
3. 最頻値は GROUP BY で数えて、多い順の 1 行目。items なら 3（115 件）。
   For the mode, count with GROUP BY and take the first row. For items: 3 (115 orders).

```sql
SELECT items, COUNT(*) AS n FROM kumo_orders GROUP BY items ORDER BY n DESC LIMIT 1;
```

よくある間違い Common mistakes

✕
```
SELECT amount FROM kumo_orders
LIMIT 1 OFFSET 200;
```

実行結果 1行 1 row

amount
~~4390~~
6820

→ 結果の値がちがう
→ different values in the result

ORDER BY がないと、行は金額の順に並ばない（ここでは日付順）。真ん中の行は、並べてから取る。
Without ORDER BY the rows are not sorted by amount (here they are in date order). Sort first, then take the middle row.

○
```
SELECT amount FROM kumo_orders
ORDER BY amount LIMIT 1 OFFSET 200;
```

Excel でやってみる Excel (Microsoft 365)

1. アプリの「CSV」ボタンで表を保存し、
   Excel で開く。Ctrl + T でテーブルにして、
   名前を kumo_orders にする。
   Save the table with the app's CSV button and open it in Excel. Press Ctrl + T to make a table and name it kumo_orders.
2. 平均（小数第 1 位）・中央値・最頻値：
   Mean (1 decimal place), median and mode:

```
=ROUND(AVERAGE(kumo_orders[amount]),1)
=MEDIAN(kumo_orders[amount])
=MODE.SNGL(kumo_orders[items])
```

SQL と同じ数字になれば正解。
If you get the same numbers as the SQL, you are right.

Python でやってみる

Python (pandas・VS Code / Jupyter)

1. CSV をノートブックと同じフォルダに置き、
   pandas で読み込む。
   Put the CSV in the same folder as your notebook and read it with pandas.

```
import pandas as pd
df = pd.read_csv("kumo_orders.csv")
```

2. 平均・中央値・最頻値と、ヒストグラム：
   Mean, median, mode and a histogram:

```
print(round(df["amount"].mean(), 1),
df["amount"].median())
print(df["items"].value_counts().head(1))
df["amount"].plot.hist(bins=30)
```

SQL と同じ数字になれば正解。
If you get the same numbers as the SQL, you are right.

やってみよう Try it

1. hotel_stays（131 行）の charge の平均と中央値を求めよう。
   Find the mean and median of charge in hotel_stays (131 rows).
   結果：1 行 1 row

2. gym_visits（161 行）の minutes の中央値を求めよう。
   Find the median of minutes in gym_visits (161 rows).
   結果：1 行 1 row

3. factory_lots の defects の最頻値と、その件数を求めよう。
   Find the mode of defects in factory_lots and how many rows have it.
   結果：1 行 1 row

分析 Unit A4

散らばりを測る 標準偏差

Measure the spread

アプリで練習
Practice in the app

SQL Excel Python

エリアマネージャー Area manager

「売上が安定している店はどこ？」平均だけでは分からない。

“Which store has steady sales?” The mean alone cannot tell you.

範囲・四分位数・標準偏差で散らばりを比べられる。

You can compare spread with the range, quartiles and the standard deviation.

統計の基礎 Statistics basics

- 範囲（range）= 最大値 − 最小値。極端な値 1 つで大きく変わる
  Range = max − min. One extreme value changes it a lot
- 四分位数：Q1（25%）・中央値・Q3（75%）。IQR = Q3 − Q1 は真ん中半分の幅
  Quartiles: Q1 (25%), median, Q3 (75%). IQR = Q3 − Q1 is the width of the middle half
- 標準偏差（standard deviation）：平均から、だいたいどのくらい離れているか
  Standard deviation: roughly how far values are from the mean

標本分散 $s^2 = \Sigma(x - \bar{x})^2 \div (n - 1)$　　**標準偏差** $s = \sqrt{s^2}$

SQL では同じ値を $\Sigma(x-\bar{x})^2 = \Sigma x^2 - (\Sigma x)^2 \div n$ で計算する。n − 1 で割るのは、Excel の STDEV.S、pandas の .std() と同じ。

In SQL we use $\Sigma(x-\bar{x})^2 = \Sigma x^2 - (\Sigma x)^2 \div n$. Dividing by n − 1 is the same as Excel STDEV.S and pandas .std().



店ごとの箱ひげ図。箱が Q1〜Q3、緑の線が中央値、点が平均、丸は外れ値。

Box plot per store: box = Q1–Q3, green line = median, dot = mean, circles = outliers.

見てみる See it

店ごとに、件数・平均・標準偏差を求め、標準偏差の小さい順に並べる。

For each store, find the count, mean and standard deviation, smallest standard deviation first.

```sql
SELECT store, COUNT(*) AS n,
       ROUND(AVG(amount), 1) AS mean_amount,
       ROUND(SQRT((SUM(amount * amount) - 1.0 * SUM(amount) * SUM(amount) / COUNT(*))
                  / (COUNT(*) - 1)), 1) AS sd_amount
FROM kumo_orders
GROUP BY store
ORDER BY sd_amount;
```

結果 4 行 4 rows

store	n	mean_amount	sd_amount
Sakae	112	4221.4	1508.8
Umeda	94	5315.6	4829.2
Shibuya	87	5560.6	5752
Online	108	6385.8	7067.8

Sakae は標準偏差がいちばん小さく（1,508.8）、売上が安定している。Online はいちばん散らばっている。

Sakae has the smallest standard deviation (1,508.8): the steadiest. Online varies the most.

ポイント Points

1. 平均が違うグループは、変動係数 = s ÷ $\bar{x}$ で比べるとよい。
   For groups with different means, compare the coefficient of variation = s ÷ $\bar{x}$.
2. 範囲は MAX − MIN で求められる。
   The range is MAX − MIN.
   `SELECT store, MAX(amount) - MIN(amount) AS range_amount FROM kumo_orders GROUP BY store;`

よくある間違い Common mistakes

```sql
SELECT ROUND(SQRT((SUM(amount * amount) - 1.0 * SUM(amount) * SUM(amount) / COUNT(*))
                  / COUNT(*)), 1) AS sd
FROM kumo_orders;
```

実行結果 1 行 1 row

sd
5214
5207.5

→ **結果の値がちがう**
→ different values in the result

n で割ると母集団の式（STDEV.P）になる。標本は n − 1 で割る。
Dividing by n is the population formula (STDEV.P). For a sample, divide by n − 1.

```sql
SELECT ROUND(SQRT((SUM(amount * amount) - 1.0 * SUM(amount) * SUM(amount) / COUNT(*))
                  / (COUNT(*) - 1)), 1) AS sd
FROM kumo_orders;
```

Excel でやってみる Excel (Microsoft 365)

1. アプリの「CSV」ボタンで表を保存し、Excel で開く。
   Ctrl + T でテーブルにして、名前を kumo_orders にする。
   Save the table with the app's CSV button and open it in Excel. Press Ctrl + T to make a table and name it kumo_orders.
2. 挿入 → ピボットテーブル。store を「行」、amount を 3 回「値」へ。
   値フィールドの設定で個数・平均・標本標準偏差にする。
   Insert → PivotTable. store to Rows, amount three times to Values; set them to Count, Average and StdDev.
3. 1つの店だけなら式でもよい：
   For one store you can also use a formula:

```
=ROUND(STDEV.S(FILTER(kumo_orders[amount],kumo_orders[store]="Sakae")),1)
```

4. 箱ひげ図：挿入 → 統計グラフ → 箱ひげ図。
   Box plot: Insert → Statistic Chart → Box and Whisker.

SQL と同じ数字になれば正解。
If you get the same numbers as the SQL, you are right.

Python でやってみる

Python (pandas · VS Code / Jupyter)

1. CSV をノートブックと同じフォルダに置き、pandas で読み込む。
   Put the CSV in the same folder as your notebook and read it with pandas.

```
import pandas as pd
df = pd.read_csv("kumo_orders.csv")
```

2. 店ごとの件数・平均・標準偏差と、箱ひげ図：
   Count, mean and standard deviation per store, and a box plot:

```
df.groupby("store")["amount"].agg(["count", "mean", "std"]).round(1).sort_values("std")
df.boxplot(column="amount", by="store")
```

SQL と同じ数字になれば正解。
If you get the same numbers as the SQL, you are right.

やってみよう Try it

1 helpdesk_tickets の team ごとに、minutes の標準偏差を求めよう。
Find the standard deviation of minutes for each team in helpdesk_tickets.
結果：3 行
3 rows

2 cafe_sales の shop ごとに、amount の範囲（最大 − 最小）を求めよう。
Find the range (max − min) of amount for each shop in cafe_sales.
結果：3 行
3 rows

3 factory_lots の line ごとに weight_g の標準偏差を求め、いちばん安定したラインを答えよう。
Find the standard deviation of weight_g per line in factory_lots. Which line is the most stable?
結果：3 行
3 rows

分析 Unit A5

度数分布とヒストグラム FLOOR・GROUP BY

Frequency tables and histograms

アプリで練習
Practice in the app

SQL Excel Python

店長 Store manager

「どのくらいの金額の注文がいちばん多い？」値を区切って数えよう。

“What size of order is the most common?” Split the values into ranges and count.

階級を決めて度数分布表を作り、ヒストグラムの形を読める。

You can make a frequency table with bins and read the shape of a histogram.

統計の基礎 Statistics basics

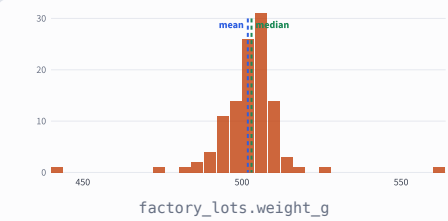
階級（bin）の幅を決め、各階級の行数（度数）を数える。
全体に対する割合が相対度数。

Choose a bin width and count the rows in each bin (frequency). The share of all rows is the relative frequency.

```
階級の始まり = FLOOR(x ÷ 幅) × 幅
```

形の読み方 Reading the shape

- 左右対称で山が１つ：平均 ≈ 中央値（製品の重さ）
  Symmetric, one peak: mean ≈ median (weight of products)
- 右に長いすそ：平均 > 中央値（お金、待ち時間）
  Long right tail: mean > median (money, waiting time)
- 山が２つ：違うグループが混ざっている。分けてから見る
  Two peaks: two groups are mixed — split them and look again





左は左右対称、右は右に長いすそ。
右では平均（青）が中央値（緑）より右にある。

Left: symmetric. Right: long right tail, where the mean (blue) is to the right of the median (green).

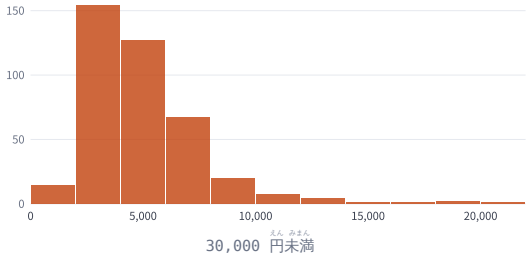
見てみる See it

amount を 2,000 円ずつの階級に分け、階級ごとの件数を数える。

Split amount into bins of 2,000 yen and count the orders in each bin.

```sql
SELECT FLOOR(1.0 * amount / 2000) * 2000 AS bin,
       COUNT(*) AS n
FROM kumo_orders
GROUP BY bin
ORDER BY bin;
```

bin	n	bin	n
0	14	14000	1
2000	154	16000	1
4000	127	18000	2
6000	67	20000	1
8000	20	46000	1
10000	7	54000	1
12000	4	68000	1



bin は階級の始まり。2000 は「2,000 円以上 4,000 円未満」。

bin is the start of the bin: 2000 means “2,000 to under 4,000 yen”.

ポイント Points

1. 相対度数（%）は、全体の件数をサブクエリで求めて割る。
   For the relative frequency (%), divide by the total count from a subquery.
   ```
   SELECT items, COUNT(*) AS n, ROUND(100.0 * COUNT(*) / (SELECT COUNT(*) FROM kumo_orders), 1) AS pct FROM
   kumo_orders GROUP BY items;
   ```
2. 幅が広すぎると形が消え、狭すぎるとギザギザになる。√n 個くらいの階級が目安。
   Too wide hides the shape, too narrow looks noisy. About √n bins is a good start.

よくある間違い Common mistakes

```sql
SELECT amount, COUNT(*) AS n
FROM kumo_orders
GROUP BY amount;
```

実行結果 313 行 313 rows

amount	n
0	14
2000	154
4000	127
6000	67
8000	20
10000	7

… 全部で 313 行

→ 313 行になる（正しくは 14 行）

→ 313 rows (correct: 14 rows)

金額そのものでまとめると、ほとんどの行が 1 件ずつになり、形が見えない。

Grouping by the amount itself gives almost one row per order, and you cannot see the shape.

```sql
SELECT FLOOR(1.0 * amount / 2000) * 2000 AS bin, COUNT(*) AS n
FROM kumo_orders
GROUP BY bin;
```

Excel でやってみる Excel (Microsoft 365)

1. アプリの「CSV」ボタンで表を保存し、Excel で開く。
   Ctrl + T でテーブルにして、名前を kumo_orders にする。
   Save the table with the app's CSV button and open it in Excel. Press Ctrl + T to make a table and name it kumo_orders.
2. テーブルの右に bin 列を足し、
   ピボットテーブルで bin を「行」、amount の個数を「値」へ。
   Add a bin column, then a PivotTable: bin to Rows, Count of amount to Values.

```
=FLOOR.MATH([@amount]/2000)*2000
```

3. ヒストグラム：amount の列を選び、
   挿入 → 統計グラフ → ヒストグラム。
   ビンの幅を 2000 にする。
   Histogram: select amount → Insert → Statistic Chart → Histogram; set the bin width to 2000.

SQL と同じ数字になれば正解。

If you get the same numbers as the SQL, you are right.

Python でやってみる Python (pandas · VS Code / Jupyter)

1. CSV をノートブックと同じフォルダに置き、
   pandas で読み込む。
   Put the CSV in the same folder as your notebook and read it with pandas.

```
import pandas as pd
df = pd.read_csv("kumo_orders.csv")
```

2. 度数分布表とヒストグラム：
   Frequency table and histogram:

```
df["bin"] = (df["amount"] // 2000) * 2000
print(df.groupby("bin").size())
import numpy as np
df["amount"].plot.hist(bins=np.arange(0, 70001, 2000))
```

SQL と同じ数字になれば正解。

If you get the same numbers as the SQL, you are right.

やってみよう Try it

1 courier_jobs の fee を 500 円ずつの階級に分けて数えよう。
Count the fee of courier_jobs in bins of 500 yen.

結果：8 行
8 rows

2 hotel_stays の nights ごとの件数と相対度数（%）を求めよう。
Find the count and relative frequency (%) of each nights value in hotel_stays.

結果：6 行
6 rows

3 factory_lots の weight_g を 5 g ずつの階級に分けて数え、形を言葉で説明しよう。
Count weight_g of factory_lots in bins of 5 g and describe the shape in words.

結果：12 行
12 rows

分析 Unit A6

標準化と外れ値 z 得点

Standard scores and outliers

アプリで練習
Practice in the app

SQL Excel Python

経理部 Accounting

「おかしな注文がないか確かめて。」平均からどれだけ離れているかで探そう。

"Check for strange orders." Look for values far from the mean.

z 得点を計算し、外れ値の候補を見つけて確かめられる。

You can calculate z-scores and find outlier candidates to check.

統計の基礎 Statistics basics

```
z = (x − x̄) ÷ s      偏差値 (T-score) = 50 + 10z
```

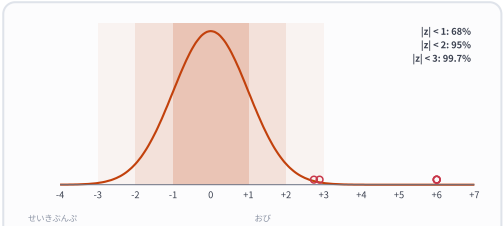
z は、平均より標準偏差いくつ分大きい（+）か小さい（−）か。
単位が違っても比べられる。

z says how many standard deviations a value is above (+) or below (−) the mean, so different units can be compared.

およそ正規分布なら、|z| < 1 に約 68%、|z| < 2 に約 95%、
|z| < 3 に約 99.7% が入る。

For roughly normal data, about 68% of values have |z| < 1, 95% have |z| < 2 and 99.7% have |z| < 3.

- 外れ値の目安：|z| ≥ 3（広めなら ≥ 2）、
  または Q1 − 1.5 × IQR より下・Q3 + 1.5 × IQR より上
  Outlier rules: |z| ≥ 3 (or ≥ 2), or below Q1 − 1.5 × IQR / above Q3 + 1.5 × IQR
- 外れ値は「間違い」ではなく「確かめる値」。
  入力ミスかまとめ買いかを確かめてから除く
  An outlier is a value to check, not a mistake: typing error or bulk order? Check before removing it



正規分布と ±1・±2・±3 の帯。
赤い丸は amount の z が大きい 5 件（右端の丸は z が 6 より大きい）。

The normal curve with the ±1, ±2, ±3 bands. Red circles: the 5 largest z of amount (circles at the right edge have z above 6).

見てみる See it

平均 5351.4、標準偏差 5214.0（A3・A4 で求めた値）を式に入れて z を計算し、大きい 5 件を出す。

Put the mean 5351.4 and the standard deviation 5214.0 (from A3 and A4) into the formula and list the 5 largest z.

```sql
SELECT order_id, amount,
       ROUND((amount - 5351.4) / 5214.0, 2) AS z
FROM kumo_orders
ORDER BY z DESC
LIMIT 5;
```

結果 5 行 5 rows

order_id	amount	z
88	68400	12.09
98	54200	9.37
265	47800	8.14
228	20430	2.89
368	19660	2.74

z が 5 を超える注文がある。入力ミスか、法人のまとめ買いか、伝票を確かめる。

Some orders have z above 5. Check the receipts: a typing error or a bulk order by a company?

ポイント Points

1. |z| ≥ 2 の件数は WHERE で数える。kumo_orders では 7 件。
   Count |z| ≥ 2 with WHERE: 7 orders in kumo_orders.
   `SELECT COUNT(*) FROM kumo_orders WHERE ABS(amount - 5351.4) / 5214.0 >= 2;`
2. 平均と標準偏差を 1 つの SQL の中で求める方法（ウィンドウ関数）は、Unit 12 で学ぶ。
   Getting the mean and standard deviation inside the same SQL (window functions) comes in Unit 12.

よくある間違い Common mistakes

✕
```
SELECT order_id, (amount - 5351) / 5214 AS z
FROM kumo_orders ORDER BY z DESC LIMIT 5;
```

実行結果 5 行 5 rows

order_id	z
~~88~~	~~12.09~~
~~98~~	~~9.37~~
~~265~~	~~8.14~~
~~228~~	~~2.89~~
~~368~~	~~2.74~~
88	12
98	9
265	8
92	2
141	2

→ 結果の値がちがう
→ different values in the result

整数だけの式は整数の割り算になり、z の小数が消える。小数点のある数を入れる。
An expression with only integers is an integer division and loses the decimals of z. Use numbers with a decimal point.

○
```
SELECT order_id, (amount - 5351.4) / 5214.0 AS z
FROM kumo_orders ORDER BY z DESC LIMIT 5;
```

Excel でやってみる Excel (Microsoft 365)

1. アプリの「CSV」ボタンで表を保存し、Excel で開く。
   Ctrl + T でテーブルにして、名前を kumo_orders にする。
   Save the table with the app's CSV button and open it in Excel. Press Ctrl + T to make a table and name it kumo_orders.
2. 平均と標準偏差を確かめ、テーブルに z の列を足して、大きい順に並べ替える。
   Check the mean and standard deviation, add a z column and sort it from largest.

```
=ROUND(AVERAGE(kumo_orders[amount]),1)
=ROUND(STDEV.S(kumo_orders[amount]),1)
=ROUND(STANDARDIZE([@amount],5351.4,5214.0),2)
```

SQL と同じ数字になれば正解。
If you get the same numbers as the SQL, you are right.

Python でやってみる

Python (pandas · VS Code / Jupyter)

1. CSV をノートブックと同じフォルダに置き、pandas で読み込む。
   Put the CSV in the same folder as your notebook and read it with pandas.

```
import pandas as pd
df = pd.read_csv("kumo_orders.csv")
```

2. z 得点と、大きい 5 件・|z| ≥ 2 の件数：
   z-scores, the 5 largest and the count with |z| ≥ 2:

```
m, s = 5351.4, 5214.0
df["z"] = ((df["amount"] - m) / s).round(2)
print(df.nlargest(5, "z")[["order_id", "amount",
"z"]])
print((df["z"].abs() >= 2).sum())
```

SQL と同じ数字になれば正解。
If you get the same numbers as the SQL, you are right.

やってみよう Try it

1. helpdesk_tickets の minutes（平均 78.1、標準偏差 114.3）で、z が大きい 5 件の ticket_id と z を出そう。
   For minutes in helpdesk_tickets (mean 78.1, standard deviation 114.3), list ticket_id and z of the 5 largest z.
   結果：5 行 5 rows

2. factory_lots の weight_g（平均 501.8、標準偏差 10.9）で、|z| が 2 以上の件数を数えよう。
   For weight_g in factory_lots (mean 501.8, standard deviation 10.9), count the rows with |z| ≥ 2.
   結果：1 行 1 row

3. z = 1.5 の社員の偏差値はいくつ？
   What is the T-score (hensachi) of an employee with z = 1.5?
   計算で答える answer by calculation

やってみようの答え Answers to “Try it”

結果は上の 6 行まで。別の書き方でも、同じ結果なら正解。
Results show up to 6 rows. A different SQL with the same result is also right.

A1-1

```sql
SELECT COUNT(*) AS n_rows, MIN(amount) AS min_amount, MAX(amount) AS max_amount FROM cafe_sales;
```

n_rows	min_amount	max_amount
151	200	9800

A1-2

```sql
SELECT MIN(checkin_date) AS first_date, MAX(checkin_date) AS last_date FROM hotel_stays;
```

first_date	last_date
2025-01-02	2025-12-23

A1-3 ID：visit_id ／ 日付：visit_date ／ 質的：branch・member_id・trainer ／ 量的：minutes・machines
ID: visit_id / date: visit_date / qualitative: branch, member_id, trainer / quantitative: minutes, machines

A2-1

```sql
SELECT COUNT(*) - COUNT(rating) AS missing, ROUND(100.0 * (COUNT(*) - COUNT(rating)) / COUNT(*), 1) AS missing_pct FROM helpdesk_tickets;
```

missing	missing_pct
42	34.7

A2-2

```sql
SELECT COUNT(DISTINCT client_id) AS clients FROM courier_jobs;
```

clients
48

A2-3

```sql
SELECT COUNT(DISTINCT member_id) AS members, COUNT(*) AS n_rows FROM cafe_sales;
```

members	n_rows
55	151

A3-1

```sql
SELECT ROUND(AVG(charge), 1) AS mean_charge, (SELECT charge FROM hotel_stays ORDER BY charge LIMIT 1 OFFSET 65) AS median_charge FROM hotel_stays;
```

mean_charge	median_charge
35812.2	28600

A3-2

```sql
SELECT minutes FROM gym_visits ORDER BY minutes LIMIT 1 OFFSET 80;
```

minutes
65

A3-3

```sql
SELECT defects, COUNT(*) AS n FROM factory_lots GROUP BY defects ORDER BY n DESC LIMIT 1;
```

defects	n
1	43

A4-1

```sql
SELECT team, ROUND(SQRT((SUM(minutes * minutes) - 1.0 * SUM(minutes) * SUM(minutes) / COUNT(*)) / (COUNT(*) - 1)), 1) AS sd_minutes FROM helpdesk_tickets GROUP BY team;
```

team	sd_minutes
Accounts	21.6
Network	70
Software	202.4

A4-2

```sql
SELECT shop, MAX(amount) - MIN(amount) AS range_amount FROM cafe_sales GROUP BY shop;
```

shop	range_amount
Campus	1170
Park	7400
Station	9470

A4-3

```sql
SELECT line, ROUND(SQRT((SUM(weight_g * weight_g) - 1.0 * SUM(weight_g) * SUM(weight_g) / COUNT(*)) / (COUNT(*) - 1)), 1) AS s FROM factory_lots GROUP BY line ORDER BY s;
```

line	s
Line A	3.8
Line B	10
Line C	15.7

A5-1

```sql
SELECT FLOOR(1.0 * fee / 500) * 500 AS bin, COUNT(*) AS n FROM courier_jobs GROUP BY bin ORDER BY bin;
```

bin	n
500	24
1000	57
1500	37
2000	16
2500	3
3500	2

… 全部で 8 行

A5-2

```sql
SELECT nights, COUNT(*) AS n, ROUND(100.0 * COUNT(*) / (SELECT COUNT(*) FROM hotel_stays), 1) AS pct FROM hotel_stays GROUP BY nights ORDER BY nights;
```

nights	n	pct
1	31	23.7
2	29	22.1
3	36	27.5
4	27	20.6
5	7	5.3
6	1	0.8

A5-3

```sql
SELECT FLOOR(1.0 * weight_g / 5) * 5 AS bin, COUNT(*) AS n FROM factory_lots GROUP BY bin ORDER BY bin;
```

bin	n
440	1
470	1
480	1
485	3
490	10
495	18

… 全部で 12 行

A6-1

```sql
SELECT ticket_id, ROUND((minutes - 78.1) / 114.3, 2) AS z FROM helpdesk_tickets ORDER BY z DESC LIMIT 5;
```

ticket_id	z
94	7.72
43	5.62
69	2.2
26	1.82
102	1.53

A6-2

```sql
SELECT COUNT(*) AS outliers FROM factory_lots WHERE ABS(weight_g - 501.8) / 10.9 >= 2;
```

outliers
5

A6-3

偏差値 = 50 + 10 × 1.5 = 65

T-score = 50 + 10 × 1.5 = 65